

Analisis Clustering Biji Gandum

Jacky Alinson

2026-06-06

Contents

1	Pendahuluan	2
2	Load Library & Data	2
2.1	Library yang Digunakan	2
2.2	Import Data	2
2.3	Eksplorasi Awal	3
3	Preprocessing	4
4	Eksplorasi Distribusi Fitur (Boxplot)	4
5	Penentuan Jumlah Cluster Optimal	4
5.1	Elbow Method (WSS)	4
5.2	Silhouette Method	7
6	Proses Clustering	8
7	Visualisasi PCA: Ground Truth vs Hasil Clustering	8
8	Uji Stabilitas Bootstrap K-Means	9
9	Evaluasi Metrik	12
10	Tabel Perbandingan Metrik	12
11	Silhouette Plot	13
12	Profil Cluster	15
13	Heatmap Profil Cluster	16
14	Confusion Matrix	16

1 Pendahuluan

Dataset **Seeds** merupakan kumpulan data morfometrik biji gandum yang berasal dari tiga varietas berbeda (*Kama*, *Rosa*, dan *Canadian*), masing-masing berjumlah 70 sampel sehingga total terdapat **210 observasi**. Setiap sampel memiliki 7 fitur geometris yang diukur menggunakan teknik sinar-X lunak beresolusi tinggi.

Tujuan analisis ini adalah **membandingkan dua algoritma clustering tanpa pengawasan (*unsupervised*)**, yaitu K-Means dan K-Medoids (PAM), dalam mengelompokkan biji gandum berdasarkan kemiripan fitur morfologisnya tanpa menggunakan label varietas sebagai panduan selama proses clustering.

2 Load Library & Data

2.1 Library yang Digunakan

```
library(cluster)
library(factoextra)
library(ggplot2)
library(gridExtra)
library(clusterSim)
library(fpc)
library(mclust)
library(pheatmap)
library(tidyr)
```

2.2 Import Data

```
seeds <- read.table(
  "C:/Users/jackyallea/Downloads/seeds/seeds_dataset.txt",
  header = FALSE,
  sep = ",",
  col.names = c(
    "area", "perimeter", "compactness",
    "kernel_length", "kernel_width",
    "asymmetry_coef", "groove_length",
    "variety"
  )
)

cat("Dimensi Data :", nrow(seeds), "x", ncol(seeds), "\n")
```

```
## Dimensi Data : 210 x 8
```

```
cat("Missing Value:", sum(is.na(seeds)), "\n")
```

```
## Missing Value: 0
```

2.3 Eksplorasi Awal

```
str(seeds)
```

```
## 'data.frame': 210 obs. of 8 variables:
## $ area : num 15.3 14.9 14.3 13.8 16.1 ...
## $ perimeter : num 14.8 14.6 14.1 13.9 15 ...
## $ compactness : num 0.871 0.881 0.905 0.895 0.903 ...
## $ kernel_length : num 5.76 5.55 5.29 5.32 5.66 ...
## $ kernel_width : num 3.31 3.33 3.34 3.38 3.56 ...
## $ asymmetry_coef: num 2.22 1.02 2.7 2.26 1.35 ...
## $ groove_length : num 5.22 4.96 4.83 4.8 5.17 ...
## $ variety : int 1 1 1 1 1 1 1 1 1 ...
```

```
summary(seeds)
```

```
##      area      perimeter      compactness      kernel_length
## Min.   :10.59   Min.   :12.41   Min.   :0.8081   Min.   :4.899
## 1st Qu.:12.27   1st Qu.:13.45   1st Qu.:0.8569   1st Qu.:5.262
## Median :14.36   Median :14.32   Median :0.8734   Median :5.524
## Mean   :14.85   Mean   :14.56   Mean   :0.8710   Mean   :5.629
## 3rd Qu.:17.30   3rd Qu.:15.71   3rd Qu.:0.8878   3rd Qu.:5.980
## Max.   :21.18   Max.   :17.25   Max.   :0.9183   Max.   :6.675
## kernel_width asymmetry_coef groove_length      variety
## Min.   :2.630   Min.   :0.7651   Min.   :4.519   Min.   :1
## 1st Qu.:2.944   1st Qu.:2.5615   1st Qu.:5.045   1st Qu.:1
## Median :3.237   Median :3.5990   Median :5.223   Median :2
## Mean   :3.259   Mean   :3.7002   Mean   :5.408   Mean   :2
## 3rd Qu.:3.562   3rd Qu.:4.7687   3rd Qu.:5.877   3rd Qu.:3
## Max.   :4.033   Max.   :8.4560   Max.   :6.550   Max.   :3
```

```
table(seeds$variety)
```

```
##
## 1  2  3
## 70 70 70
```

Catatan: Dataset terdiri dari 210 baris dan 8 kolom. Tidak terdapat nilai hilang (*missing value*). Label varietas (**variety**) berdistribusi **seimbang** dengan masing-masing 70 sampel per kelas kondisi ideal untuk evaluasi clustering.

3 Preprocessing

Fitur ke-1 hingga ke-7 dipisahkan dari label, kemudian dilakukan **standardisasi (z-score scaling)** agar setiap fitur memiliki skala yang setara. Hal ini penting karena K-Means dan PAM menggunakan jarak Euclidean yang sensitif terhadap perbedaan satuan antar fitur.

```
X      <- seeds[, 1:7]
X_scaled <- scale(X)
```

4 Eksplorasi Distribusi Fitur (Boxplot)

```
par(mfrow = c(2, 4))
for (col in names(X)) {
  boxplot(X[[col]], main = col, col = "lightblue")
}
par(mfrow = c(1, 1))
```

Interpretasi: Sebagian besar fitur (area, perimeter, kernel_length, kernel_width, groove_length) memiliki distribusi yang relatif simetris tanpa pencilan ekstrem. Fitur `asymmetry_coef` menunjukkan distribusi yang lebih miring ke kanan (*right-skewed*) dengan beberapa pencilan di nilai tinggi, mengindikasikan variabilitas asimetri yang lebih besar antar biji. Fitur `compactness` memiliki rentang nilai sangat sempit (0.81–0.92), sehingga standardisasi menjadi penting untuk menghindari dominasi fitur berskala besar.

5 Penentuan Jumlah Cluster Optimal

5.1 Elbow Method (WSS)

```
set.seed(42)

fviz_nbclust(
  X_scaled, kmeans,
  method = "wss", k.max = 10
) +
  geom_vline(xintercept = 3, linetype = "dashed", color = "red") +
  labs(title = "Elbow Method", x = "Jumlah Cluster", y = "WSS")
```

Interpretasi: Grafik WSS (*Within-Cluster Sum of Squares*) menunjukkan penurunan tajam dari $k=1$ ke $k=2$, kemudian melambat secara signifikan mulai $k=3$. Titik “siku” (*elbow*) terbentuk jelas pada **$k=3$** , ditandai garis merah putus-putus. Penambahan cluster di atas $k=3$ tidak memberikan penurunan WSS yang berarti, sehingga $k=3$ dipilih sebagai jumlah cluster optimal berdasarkan metode ini.




Figure 1: Gambar 1. Distribusi setiap fitur morfologis biji gandum sebelum scaling.




Figure 2: Gambar 2. Elbow Method — penurunan WSS terhadap jumlah cluster.

5.2 Silhouette Method

```
fviz_nbclust(  
  X_scaled, kmeans,  
  method = "silhouette", k.max = 10  
) +  
  labs(title = "Silhouette Method")
```




Figure 3: Gambar 3. Silhouette Method — rata-rata lebar silhouette per jumlah cluster.

Interpretasi: Nilai rata-rata silhouette tertinggi diperoleh pada **k=2** (~0.46), lalu turun pada k=3 (~0.40). Meski secara matematis k=2 lebih optimal menurut metode silhouette, k=3 dipilih karena **sesuai dengan jumlah varietas yang diketahui** dari ground truth (3 kelas), serta didukung oleh hasil Elbow Method. Pada k=3, nilai silhouette masih tergolong cukup baik (~0.40), menandakan struktur cluster yang masih dapat diidentifikasi dengan baik.

Keputusan: Jumlah cluster **K = 3** dipilih berdasarkan pertimbangan gabungan antara Elbow Method, Silhouette Method, dan pengetahuan domain (3 varietas gandum).

6 Proses Clustering

```
km_result <- kmeans(X_scaled, centers = 3, nstart = 25, iter.max = 100)
pam_result <- pam(X_scaled, k = 3)
```

```
cat("\nCLUSTER SIZE K-MEANS\n")
```

```
##
## CLUSTER SIZE K-MEANS
```

```
print(km_result$size)
```

```
## [1] 67 71 72
```

```
cat("\nCLUSTER SIZE PAM\n")
```

```
##
## CLUSTER SIZE PAM
```

```
print(pam_result$clusinfo[, "size"])
```

```
## [1] 77 62 71
```

Interpretasi: K-Means menghasilkan cluster dengan ukuran yang relatif seimbang (67, 71, 72), sedangkan PAM menghasilkan distribusi yang sedikit lebih tidak merata (77, 62, 71). Cluster K-Means yang lebih proporsional konsisten dengan cara kerjanya yang mengoptimalkan pusat cluster secara iteratif, sementara PAM memilih medoid dari data aktual sehingga lebih dipengaruhi oleh kepadatan lokal data.

7 Visualisasi PCA: Ground Truth vs Hasil Clustering

```
p0 <- fviz_cluster(
  list(data = X_scaled, cluster = seeds$variety),
  ellipse = TRUE, geom = "point",
  main = "Ground Truth Variety", ggtheme = theme_minimal()
)
p1 <- fviz_cluster(
  km_result, data = X_scaled,
  ellipse = TRUE, geom = "point",
  main = "K-Means (K = 3)", ggtheme = theme_minimal()
)
p2 <- fviz_cluster(
  pam_result, data = X_scaled,
  ellipse = TRUE, geom = "point",
  main = "PAM (K = 3)", ggtheme = theme_minimal()
)
grid.arrange(p0, p1, p2, ncol = 3)
```




Figure 4: Gambar 4. Perbandingan visualisasi PCA: Ground Truth, K-Means, dan PAM.

Interpretasi: Dua komponen utama PCA mampu menjelaskan **89%** total variansi data (Dim1: 71.9%, Dim2: 17.1%). Pada plot *Ground Truth*, terlihat adanya tumpang tindih (*overlap*) antar varietas, terutama antara varietas 1 dan 2 yang menandakan tantangan inherent dalam separasi kelas pada data ini.

Hasil K-Means dan PAM secara visual menghasilkan pola cluster yang **sangat mirip satu sama lain**, dan keduanya mendekati pola ground truth. Cluster yang paling tegas terpisah adalah cluster biji berukuran besar (kanan atas) dan biji berukuran kecil (kiri bawah). Zona overlap terjadi pada cluster biji berukuran sedang, yang memang sulit dipisahkan secara geometris.

8 Uji Stabilitas Bootstrap K-Means

```
set.seed(42)
boot_km <- clusterboot(
  X_scaled,
  B = 100, bootmethod = "boot",
  clustermethod = kmeansCBI,
  k = 3, seed = 42
)
```

```
## boot 1
## boot 2
## boot 3
```

boot 4
boot 5
boot 6
boot 7
boot 8
boot 9
boot 10
boot 11
boot 12
boot 13
boot 14
boot 15
boot 16
boot 17
boot 18
boot 19
boot 20
boot 21
boot 22
boot 23
boot 24
boot 25
boot 26
boot 27
boot 28
boot 29
boot 30
boot 31
boot 32
boot 33
boot 34
boot 35
boot 36
boot 37
boot 38
boot 39
boot 40
boot 41
boot 42
boot 43
boot 44
boot 45
boot 46
boot 47
boot 48
boot 49
boot 50
boot 51
boot 52
boot 53
boot 54
boot 55
boot 56
boot 57

```
## boot 58
## boot 59
## boot 60
## boot 61
## boot 62
## boot 63
## boot 64
## boot 65
## boot 66
## boot 67
## boot 68
## boot 69
## boot 70
## boot 71
## boot 72
## boot 73
## boot 74
## boot 75
## boot 76
## boot 77
## boot 78
## boot 79
## boot 80
## boot 81
## boot 82
## boot 83
## boot 84
## boot 85
## boot 86
## boot 87
## boot 88
## boot 89
## boot 90
## boot 91
## boot 92
## boot 93
## boot 94
## boot 95
## boot 96
## boot 97
## boot 98
## boot 99
## boot 100
```

```
cat("\nBOOTSTRAP STABILITY K-MEANS\n")
```

```
##
## BOOTSTRAP STABILITY K-MEANS
```

```
print(round(boot_km$bootmean, 4))
```

```
## [1] 0.9562 0.8858 0.9177
```

Interpretasi: Uji stabilitas dengan 100 iterasi bootstrap menghasilkan nilai Jaccard rata-rata per cluster sebagai berikut:

Cluster	Jaccard
1	0.9562
2	0.8858
3	0.9177

Ketiga cluster memiliki nilai Jaccard **di atas 0.85**, yang merupakan ambang batas stabilitas tinggi. Ini berarti komposisi cluster K-Means **sangat konsisten** saat data di-resample, menunjukkan bahwa struktur cluster yang terbentuk bukan artefak dari inisialisasi acak, melainkan pola yang benar-benar ada di dalam data.

9 Evaluasi Metrik

```
dmat <- dist(X_scaled)

sil_km <- silhouette(km_result$cluster, dmat)
sil_pam <- silhouette(pam_result$clustering, dmat)

avg_sil_km <- mean(sil_km[, 3])
avg_sil_pam <- mean(sil_pam[, 3])

db_km <- index.DB(X_scaled, km_result$cluster)$DB
db_pam <- index.DB(X_scaled, pam_result$clustering)$DB

ch_km <- calinhara(X_scaled, km_result$cluster)
ch_pam <- calinhara(X_scaled, pam_result$clustering)

ari_km <- adjustedRandIndex(seeds$variety, km_result$cluster)
ari_pam <- adjustedRandIndex(seeds$variety, pam_result$clustering)
```

10 Tabel Perbandingan Metrik

```
hasil <- data.frame(
  Metode = c("K-Means", "K-Medoids (PAM)"),
  Silhouette = round(c(avg_sil_km, avg_sil_pam), 4),
  Davies_Bouldin = round(c(db_km, db_pam), 4),
  Calinski_Harabasz = round(c(ch_km, ch_pam), 2),
  ARI = round(c(ari_km, ari_pam), 4),
  Jaccard_Bootstrap = c(round(mean(boot_km$bootmean), 4), NA)
)
```

```
knitr::kable(
  hasil,
  caption = "Tabel 1. Perbandingan metrik evaluasi K-Means dan PAM",
  align   = "lrrrrr"
)
```

Table 1: Tabel 1. Perbandingan metrik evaluasi K-Means dan PAM

Metode	Silhouette	Davies_Bouldin	Calinski_Harabasz	ARI	Jaccard_Bootstrap
K-Means	0.4007	1.0047	249.78	0.7733	0.9199
K-Medoids (PAM)	0.3982	1.0115	247.33	0.7470	NA

Interpretasi:

Metrik	K-Means	PAM	Lebih Baik	Keterangan
Silhouette	0.4007	0.3982	K-Means	Kohesi & separasi cluster sedikit lebih baik
Davies-Bouldin	1.0047	1.0115	K-Means	Cluster lebih kompak dan terpisah
Calinski-Harabasz	249.78	247.33	K-Means	Rasio variansi antar/dalam cluster lebih tinggi
ARI	0.7733	0.7470	K-Means	Kesesuaian dengan label asli lebih tinggi
Jaccard Bootstrap	0.9199		K-Means	Cluster sangat stabil

Secara keseluruhan, K-Means **unggul di semua metrik** meskipun selisihnya kecil. Nilai ARI K-Means sebesar 0.77 menunjukkan kesesuaian yang cukup tinggi dengan label varietas asli, mengindikasikan bahwa fitur morfologis biji gandum memang mengandung informasi diskriminatif antar varietas.

11 Silhouette Plot

```
par(mfrow = c(1, 2))
plot(sil_km, main = "Silhouette Plot K-Means", border = NA)
plot(sil_pam, main = "Silhouette Plot PAM", border = NA)
```

```
par(mfrow = c(1, 1))
```

Interpretasi: Pada K-Means, silhouette per cluster adalah: C1=0.47, C2=0.34, C3=0.40. Cluster 1 memiliki separasi terbaik, sementara Cluster 2 adalah yang paling lemah, konsisten dengan zona overlap yang





Figure 5: Gambar 5. Silhouette plot K-Means (kiri) dan PAM (kanan).

terlihat di plot PCA. Tidak ada nilai silhouette negatif yang berarti, sehingga tidak ada observasi yang secara tegas salah ditempatkan.

Pada PAM, distribusi nilai silhouette per cluster adalah: C1=0.30, C2=0.50, C3=0.42. Cluster 2 PAM justru memiliki nilai silhouette tertinggi, namun Cluster 1 paling lemah (0.30). Rata-rata keduanya setara (~0.40), namun K-Means menunjukkan distribusi yang lebih **merata antar cluster**.

12 Profil Cluster

```
cluster_profile_km <- aggregate(X, by = list(Cluster = km_result$cluster), FUN = mean)
cat("\nPROFIL CLUSTER K-MEANS\n")
```

```
##
## PROFIL CLUSTER K-MEANS
```

```
knitr::kable(cluster_profile_km, caption = "Tabel 2. Rata-rata fitur per cluster (K-Means)", digits = 3)
```

Table 2: Tabel 2. Rata-rata fitur per cluster (K-Means)

Cluster	area	perimeter	compactness	kernel_length	kernel_width	asymmetry_coef	groove_length
1	18.495	16.203	0.884	6.176	3.698	3.632	6.042
2	14.438	14.338	0.882	5.515	3.259	2.707	5.121
3	11.857	13.248	0.848	5.232	2.850	4.742	5.102

```
cluster_profile_pam <- aggregate(X, by = list(Cluster = pam_result$clustering), FUN = mean)
cat("\nPROFIL CLUSTER PAM\n")
```

```
##
## PROFIL CLUSTER PAM
```

```
knitr::kable(cluster_profile_pam, caption = "Tabel 3. Rata-rata fitur per cluster (PAM)", digits = 3)
```

Table 3: Tabel 3. Rata-rata fitur per cluster (PAM)

Cluster	area	perimeter	compactness	kernel_length	kernel_width	asymmetry_coef	groove_length
1	14.516	14.375	0.882	5.524	3.269	2.795	5.152
2	18.674	16.281	0.885	6.207	3.715	3.591	6.070
3	11.866	13.256	0.848	5.236	2.849	4.777	5.107

Interpretasi (K-Means):

Cluster	Karakteristik Dominan	Identifikasi
C1	Area (18.5), perimeter (16.2), groove_length (6.0) besar	Biji besar Varietas Rosa
C2	Nilai sedang di semua fitur	Biji sedang Varietas Kama
C3	Area kecil (11.9), asymmetry_coef tinggi (4.7)	Biji kecil & asimetris Varietas Canadian

Profil PAM menghasilkan karakteristik yang sangat serupa, hanya berbeda pada penomoran cluster. Cluster berukuran besar, sedang, dan kecil dapat diidentifikasi dengan jelas dari kedua metode.

13 Heatmap Profil Cluster

```
profile_km_scaled <- aggregate(X_scaled, by = list(Cluster = km_result$cluster), FUN = mean)
rownames(profile_km_scaled) <- paste("Cluster", profile_km_scaled$Cluster)
profile_km_scaled <- profile_km_scaled[, -1]
pheatmap(profile_km_scaled, main = "Cluster Profile Heatmap - K-Means")
```

```
profile_pam_scaled <- aggregate(X_scaled, by = list(Cluster = pam_result$clustering), FUN = mean)
rownames(profile_pam_scaled) <- paste("Cluster", profile_pam_scaled$Cluster)
profile_pam_scaled <- profile_pam_scaled[, -1]
pheatmap(profile_pam_scaled, main = "Cluster Profile Heatmap - PAM")
```

Interpretasi: Heatmap mengkonfirmasi pola profil cluster dari tabel sebelumnya dalam format visual. Warna **merah** menunjukkan nilai di atas rata-rata dan warna **biru** menunjukkan nilai di bawah rata-rata. Pola dendrogram yang identik antara K-Means dan PAM menunjukkan bahwa kedua algoritma mengidentifikasi **struktur hierarki yang sama** dalam data: Cluster besar dan sedang lebih mirip satu sama lain dibanding dengan cluster kecil, terutama pada fitur dimensi fisik (area, perimeter, groove_length). Fitur asymmetry_coef adalah pembeda utama yang kontras terhadap cluster lainnya pada cluster biji kecil.

14 Confusion Matrix

```
cat("\nCONFUSION MATRIX K-MEANS\n")
```

```
##
## CONFUSION MATRIX K-MEANS
```

```
cm_km <- table(Actual = seeds$variety, Cluster = km_result$cluster)
print(cm_km)
```




Figure 6: Gambar 6. Heatmap profil cluster K-Means (nilai terstandarisasi).




Figure 7: Gambar 7. Heatmap profil cluster PAM (nilai terstandarisasi).

```
##          Cluster
## Actual   1   2   3
##         1   2 62   6
##         2 65   5   0
##         3   0   4 66
```

```
cat("\nCONFUSION MATRIX PAM\n")
```

```
##
## CONFUSION MATRIX PAM
```

```
cm_pam <- table(Actual = seeds$variety, Cluster = pam_result$clustering)
print(cm_pam)
```

```
##          Cluster
## Actual   1   2   3
##         1 64   1   5
##         2   9 61   0
##         3   4   0 66
```

Interpretasi (K-Means): Dari confusion matrix, dapat dihitung akurasi pengklasteran (setelah penyesuaian label):

- **Varietas 1 - Cluster 2:** 62 dari 70 benar (89%), 6 salah ke C3, 2 ke C1
- **Varietas 2 - Cluster 1:** 65 dari 70 benar (93%), 5 salah ke C2
- **Varietas 3 - Cluster 3:** 66 dari 70 benar (94%), 4 salah ke C2

Kesalahan klasifikasi terbanyak terjadi antara Varietas 1 dan 2, konsisten dengan zona tumpang tindih yang terlihat di plot PCA.

Interpretasi (PAM): - **Varietas 1 - Cluster 1:** 64 dari 70 benar (91%) - **Varietas 2 - Cluster 2:** 61 dari 70 benar (87%) - **Varietas 3 - Cluster 3:** 66 dari 70 benar (94%)

PAM sedikit lebih lemah dalam memisahkan Varietas 2, namun lebih baik dalam memisahkan Varietas 1, dibanding K-Means.

15 Grafik Perbandingan Metrik

```
metric_plot <- hasil[, c("Metode", "Silhouette", "ARI")]
metric_plot <- pivot_longer(metric_plot, cols = c(Silhouette, ARI),
                             names_to = "Metric", values_to = "Value")

ggplot(metric_plot, aes(x = Metric, y = Value, fill = Metode)) +
  geom_col(position = "dodge") +
  labs(title = "Perbandingan K-Means vs PAM",
       x = NULL, y = "Nilai Metrik") +
  theme_minimal()
```




Figure 8: Gambar 8. Perbandingan nilai Silhouette dan ARI antara K-Means dan PAM.

Interpretasi: Grafik batang memperjelas bahwa K-Means secara konsisten menghasilkan nilai yang lebih tinggi pada kedua metrik. Selisih ARI (~ 0.026) lebih besar secara relatif dibanding selisih Silhouette (~ 0.002), menunjukkan bahwa K-Means memiliki **kesesuaian lebih baik dengan label asli** bukan hanya struktur internal cluster yang lebih baik.

16 Kesimpulan

```
best_sil <- ifelse(avg_sil_km > avg_sil_pam, "K-Means", "PAM")
best_db  <- ifelse(db_km < db_pam,          "K-Means", "PAM")
best_ch  <- ifelse(ch_km > ch_pam,          "K-Means", "PAM")
best_ari <- ifelse(ari_km > ari_pam,         "K-Means", "PAM")
votes    <- c(best_sil, best_db, best_ch, best_ari)
winner   <- names(sort(table(votes), decreasing = TRUE))[1]
```

```
cat("Silhouette      :", best_sil, "\n")
```

```
## Silhouette      : K-Means
```

```
cat("Davies-Bouldin  :", best_db,  "\n")
```

```
## Davies-Bouldin   : K-Means
```

```
cat("Calinski-Harabasz :", best_ch,  "\n")
```

```
## Calinski-Harabasz : K-Means
```

```
cat("ARI            :", best_ari, "\n")
```

```
## ARI              : K-Means
```

```
cat("\nMetode terbaik secara keseluruhan:", winner, "\n")
```

```
##
```

```
## Metode terbaik secara keseluruhan: K-Means
```

Berdasarkan analisis clustering pada dataset Seeds dengan 210 sampel dan 7 fitur morfologis biji gandum, dapat disimpulkan:

1. **Jumlah cluster optimal adalah $K=3$** , didukung oleh Elbow Method dan selaras dengan struktur data tiga varietas (*Kama*, *Rosa*, *Canadian*).
2. **K-Means unggul di semua metrik evaluasi** dengan Silhouette (0.4007 vs 0.3982), Davies-Bouldin (1.0047 vs 1.0115), Calinski-Harabasz (249.78 vs 247.33), dan ARI (0.7733 vs 0.7470). Meskipun selisihnya kecil, K-Means secara konsisten memberikan hasil yang lebih baik.

3. **K-Means sangat stabil** dengan nilai Jaccard Bootstrap rata-rata 0.9199 (>0.85), menunjukkan cluster yang terbentuk bukan hasil kebetulan inisialisasi.
 4. **Kedua metode berhasil mengidentifikasi tiga kelompok morfologis**: biji besar (dominan Varietas Rosa), biji sedang (dominan Varietas Kama), dan biji kecil dengan asimetri tinggi (dominan Varietas Canadian). Kesalahan klasifikasi terjadi terutama di zona tumpang tindih antara Varietas 1 dan 2.
 5. **K-Means direkomendasikan** sebagai metode clustering untuk dataset ini, mengingat keunggulan di semua dimensi evaluasi dan kestabilannya yang tinggi.
-